

Likelihood függvény

Likelihood-függvény

Ha X_1, \dots, X_n i.i.d. véletlen változók, és $f(x|\theta)$ eloszlás függvény (PDF). Ekkor a **likelihood függvényt** úgy definiáljuk, hogy

$$\mathcal{L}(\theta) = \prod_{i=1}^n f(X_i|\theta).$$

A **log-likelihood függvényt** pedig a következő módon írjuk fel:

$$\ell(\theta) = \log \mathcal{L}(\theta)$$

Maximum likelihood becslő

A **maximum likelihood** becslő (MLE), jelölése $\hat{\theta}_n$, nem más, mint θ azon értéke, amely mellett a likelihood függvény ($\mathcal{L}(\theta)$) a legnagyobb.

Likelihood függvény: megjegyzés

Mivel a logaritmus egy szigorúan monotone növekvő transzformáció, ezért a log-likelihood és a likelihood függvények ugyanazon θ értékek mellett veszik fel a szélső értékeiket. Ebből következik, hogy a log-likelihood függvény maximumának megkeresése ugyanarra a válaszra vezet. A gyakorlatban gyakrabban alkalmazzuk a log-likelihoodot, mert könnyebben kiszámítható.

Ha $\mathcal{L}(\theta)$ -t megszorozzuk bármely olyan tetszőleg pozitív c számmal, amely nem függ θ -tól, akkor a MLE nem változik. Emiatt a likelihood függvényben lévő konstans értékeket gyakran el is hagyjuk.

MLE tulajdonságok

Bizonyos regularitási feltételek teljesülése esetén az MLE elvű becslő olyan jó tulajdonságokkal rendelkezik, amelyek népszerű becslési módszerré teszik.

Tulajdonságok

- 1 Invariancia: Ha $\hat{\theta}_{MLE}$ a legjobb becslésünk θ -ra, akkor, $g(\hat{\theta}_{MLE})$ a a legjobb becslés $g(\theta)$ -ra
- 2 Konzisztencia: $\hat{\theta} \xrightarrow{p} \theta$
- 3 Aszimptotikus normalitás: $\frac{\hat{\theta} - \theta}{se} \xrightarrow{d} N(0, 1)$
- 4 Aszimptotikus hatékonyság

Regresszió

A hipotézis vizsgálat során, annak érdekében, hogy következtetni tudjunk a becsült paraméterekről, feltevéseket tettünk a hibatagok eloszlására vonatkozóan. A Maximum Likelihood (MLE) elvű becslés során ezt a feltevést a becslési folyamat során is felhasználjuk.

Ha feltesszük, hogy a hibatagok:

- 1 normális eloszlásúak
- 2 homoszkedasztikusak
- 3 feltételesen korrelálatlanok

akkor a likelihood függvény:

$$\mathcal{L}(\beta, \sigma^2) = (2\pi\sigma^2)^{-\frac{n}{2}} \exp - \frac{(Y - X\beta)^T(Y - X\beta)}{2\sigma^2}.$$

A log-likelihood függvény:

$$\ell(\beta, \sigma^2) = -\frac{n}{2}\log(2\pi) - \frac{n}{2}\log(\sigma^2) - \frac{(Y - X\beta)^T(Y - X\beta)}{2\sigma^2}$$

Elsőrendű feltételek

A log-likelihood függvény maximuma az ismeretlen paraméterek függvényében úgy számolható ki, hogy vesszük azok parciális deriváltjait:

$$\begin{aligned}\frac{\partial \ell(\beta, \sigma^2)}{\partial \beta} &= \frac{X^T(Y - X\hat{\beta})}{\sigma^2} = 0 \\ \frac{\partial \ell(\beta, \sigma^2)}{\partial \sigma^2} &= -\frac{n}{2\hat{\sigma}^2} + \frac{(Y - X\hat{\beta})^T(Y - X\hat{\beta})}{2\hat{\sigma}^4} = 0.\end{aligned}$$

Ezen egyenleteket felhasználva arra a megoldásra jutunk, hogy:

$$\begin{aligned}\hat{\beta}_{MLE} &= (X^T X)^{-1} X^T Y \\ \hat{\sigma}_{MLE}^2 &= n^{-1} (Y - X\hat{\beta})^T (Y - X\hat{\beta}) = n^{-1} \epsilon^T \epsilon\end{aligned}$$

Ahogy látható, a MLE elven becsült regressziós együtthatók **megegyeznek** az OLS elven becsült együtthatókkal, azonban a varianciák különböznek. Az MLE a korrigálatlan minta varianciát adja vissza. (Emiatt lesz csak aszimptotikusan torzítatlan a becslés)

Legkisebb varianciájú torzítatlan becslő

Amennyiben **feltesszük**, hogy a Gauss-Markov feltevések teljesültek, és a hibatag normális eloszlású, akkor

$$\hat{\beta} = \hat{\beta}_{MLE}$$

a legkisebb varianciájú β torzítatlan becslői körében.

A Gauss-Markov tételhez képest ezen tétel kis különbsége annál lényegesebb. A MLE elvű becslés esetén - a feltételek teljesülése mellett - már nem csak a lineáris, hanem a nem-lineáris becslők körében sem találunk kisebb varianciájút.